

Inteligencia Artificial  
**Act8: Laboratorio de Álgebra Lineal**

Arturo Garza Rodríguez

February 2025

# 1. Operaciones con matrices y determinantes

## 1.1. Matriz inversa

### 1.1.1. Obtener la matriz inversa

Obtener la matriz inversa de:

$$F = \begin{pmatrix} 1 & 2 & 3 \\ 0 & 1 & 4 \\ 5 & 6 & 0 \end{pmatrix}$$

Para obtener la matriz inversa de una matriz, usamos el método adjunto definido como:

$$A^{-1} = \frac{Adj(A)}{|A|} \quad (1)$$

Donde  $A^{-1}$  es la matriz inversa,  $Adj(A)$  la matriz A adjunta de A y  $|A|$  el determinante de A. Por simplicidad, renombramos la matriz F como A.

#### Determinante de A

Para obtener el determinante de la matriz de 3x3 podemos utilizar el método de la lluvia (Regla de Sarrus).

$$|A| = (1)(1)(0) + (2)(4)(5) + (3)(0)(6) - (3)(1)(5) - (2)(0)(0) - (1)(4)(6) = 0 + 40 + 0 - 15 - 0 - 24$$

$$|A| = 40 - 39 = 1$$

#### Adjunta y matriz de cofactores

Obtener la matriz adjunta solo es posible cuando la matriz a tratar es cuadrada, en este caso es de 3x3, por lo que sí es posible. El proceso sigue aplicando la siguiente fórmula a cada elemento de A para obtener la matriz de cofactores, y luego transponer esta matriz resultante para obtener la adjunta de A:

$$a_{i,j} = (-1)^{i+j} \cdot |m_{i,j}|$$

Donde  $a_{i,j}$  es el elemento de la matriz adjunta y  $|m_{i,j}|$  es el determinante de la matriz menor complementaria. Para evitar cálculos extra, podemos definir una matriz de signos que irán alternando entre positivo y negativo por la paridad entre filas y columnas.

$$Signos = \begin{pmatrix} + & - & + \\ - & + & - \\ + & - & + \end{pmatrix}$$

Estos signos serán aplicados a los determinantes que encontremos asociados a cada término para obtener el valor de  $a_{i,j}$ . Entonces, definimos  $A^t$  como:

$$Cof(A) = \begin{pmatrix} + \begin{vmatrix} 1 & 4 \\ 6 & 0 \end{vmatrix} & - \begin{vmatrix} 0 & 4 \\ 5 & 0 \end{vmatrix} & + \begin{vmatrix} 0 & 1 \\ 5 & 6 \end{vmatrix} \\ - \begin{vmatrix} 2 & 3 \\ 6 & 0 \end{vmatrix} & + \begin{vmatrix} 1 & 3 \\ 5 & 0 \end{vmatrix} & - \begin{vmatrix} 1 & 2 \\ 5 & 6 \end{vmatrix} \\ + \begin{vmatrix} 2 & 3 \\ 1 & 4 \end{vmatrix} & - \begin{vmatrix} 1 & 3 \\ 0 & 4 \end{vmatrix} & + \begin{vmatrix} 1 & 2 \\ 0 & 1 \end{vmatrix} \end{pmatrix}$$

$$Cof(A) = \begin{pmatrix} -24 & 20 & -5 \\ 18 & -15 & 4 \\ 5 & -4 & 1 \end{pmatrix}$$

$$Adj(A) = Cof(A)^t = \begin{pmatrix} -24 & 18 & 5 \\ 20 & -15 & -4 \\ -5 & 4 & 1 \end{pmatrix}$$

### Inversa de A

Para obtener la inversa de  $A$ , sustituimos los resultados en 1:

$$A^{-1} = \frac{\begin{pmatrix} -24 & 18 & 5 \\ 20 & -15 & -4 \\ -5 & 4 & 1 \end{pmatrix}}{1} = \begin{pmatrix} -24 & 18 & 5 \\ 20 & -15 & -4 \\ -5 & 4 & 1 \end{pmatrix}$$

Por lo tanto, la inversa de  $A$  antes  $F$  es:

$$F^{-1} = \begin{pmatrix} -24 & 18 & 5 \\ 20 & -15 & -4 \\ -5 & 4 & 1 \end{pmatrix}$$

#### 1.1.2. Verificación de resultado

Para comprobar el que la matriz resultante es la inversa de  $F$ , podemos hacer uso de la siguiente propiedad:

$$A \cdot A^{-1} = I_n$$

Donde  $n$  viene de  $n \times n$ , el tamaño de la matriz  $A$ . Se cumple que para toda matriz, la multiplicación de la matriz original y la inversa deber ser igual a la identidad de 'grado' (tamaño)  $n$ .

$$\begin{aligned} &\rightarrow \begin{pmatrix} 1 & 2 & 3 \\ 0 & 1 & 4 \\ 5 & 6 & 0 \end{pmatrix} \cdot \begin{pmatrix} -24 & 18 & 5 \\ 20 & -15 & -4 \\ -5 & 4 & 1 \end{pmatrix} \\ &= \begin{pmatrix} -24 + 40 - 15 & 18 - 30 + 12 & 5 - 8 + 3 \\ 0 + 20 - 20 & 0 - 15 + 16 & 0 - 4 + 4 \\ -120 + 120 + 0 & 90 - 90 + 0 & 25 - 24 + 0 \end{pmatrix} = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{pmatrix} \end{aligned}$$

**Se ha demostrado, que la matriz obtenida es la inversa de la original. ■**

### 1.2. Demostración de propiedad de que el determinante de un producto de matrices es igual al producto de los determinantes

Para demostrar esto, haremos uso de las matrices elementales.

### 1.2.1. Descomposición de una matriz en matrices elementales

Sabemos que cualquier matriz cuadrada  $A$  de orden  $n$  no singular puede reescribirse como un producto de matrices elementales:

$$A = E_1 E_2 \dots E_k$$

donde cada  $E_i$  es una matriz elemental obtenida mediante operaciones elementales sobre filas.

Análogamente, si  $B$  también es invertible, se puede escribir como:

$$B = F_1 F_2 \dots F_m$$

donde  $F_j$  son matrices elementales.

### 1.2.2. Determinantes de matrices elementales

Las matrices elementales tienen propiedades sencillas respecto al determinante:

1. Si  $E_i$  es una matriz de intercambio de filas, entonces  $\det E_i = -1$ .
2. Si  $E_i$  es una matriz de escalamiento de fila por un escalar  $\lambda$ , entonces  $\det E_i = \lambda$ .
3. Si  $E_i$  es una matriz de una fila multiplicada por un escalar a otra fila, entonces  $\det E_i = 1$ .

Para cualquier matriz elemental  $E_i$ :

$$\det(E_i A) = \det E_i \cdot \det A$$

### 1.2.3. Producto de matrices A y B

Dado que  $A = E_1 E_2 \dots E_k$  y  $B = F_1 F_2 \dots F_m$ , su producto es:

$$AB = (E_1 E_2 \dots E_k)(F_1 F_2 \dots F_m)$$

Obtenemos el determinante de ambos lados:

$$\det(AB) = \det(E_1 E_2 \dots E_k F_1 F_2 \dots F_m)$$

Usando la propiedad mencionada anteriormente:

$$\det(AB) = \det(E_1) \det(E_2) \dots \det(E_k) \det(F_1) \det(F_2) \dots \det(F_m)$$

Pero:

$$\det(A) = \det(E_1) \det(E_2) \dots \det(E_k)$$

y

$$\det(B) = \det(F_1) \det(F_2) \dots \det(F_m)$$

Entonces:

$$\det(AB) = \det(A) \det(B)$$

**Se ha demostrado que el determinante de un producto de matrices es igual al producto de determinantes** ■

## 2. Sistemas de ecuaciones lineales

### 2.1. Método de Gauss-Seidel

Resuelva el siguiente sistema por el método de Gauss-Seidel:

$$\begin{cases} 4x - y + z = 7 \\ -2x + 4y - 2z = 1 \\ x - y + 3z = 5 \end{cases}$$

El método de Gauss-Seidel es un algoritmo iterativo para resolver sistemas de ecuaciones lineales  $Ax = b$  que actualiza cada variable en función de los valores más recientes, acelerando la convergencia en matrices diagonales dominantes.

#### Paso 1

Despejamos las 3 variables, una de cada ecuación:

$$\begin{aligned} x &= \frac{7 + y - z}{4} \\ y &= \frac{1 + 2x + 2z}{4} \\ z &= \frac{5 - x + y}{3} \end{aligned}$$

Definimos valores iniciales para cada variable como:  $x = 0, y = 0, z = 0$ .

## Proceso

El proceso consiste en sustituir los valores más recientes encontrados en las ecuaciones despejadas: Por cuestiones de presentación he redondeado cada resultado a

Iteración	$x_1$	$x_2$	$x_3$
0	0.0000	0.0000	0.0000
1	1.7500	1.1250	1.4583
2	1.6667	1.8125	1.7153
3	1.7743	1.9948	1.7402
4	1.8137	2.0269	1.7378
5	1.8223	2.0300	1.7359
6	1.8235	2.0297	1.7354
7	1.8236	2.0295	1.7353

los primeros 4 decimales. Se ha detenido el proceso en la iteración 7 puesto que utilicé una tolerancia de 0,0005, esto significa que entre las iteraciones 6 y 7 existe una diferencia menor a 0,0005 en todas las variables, por lo que se concluye que el valor obtenido es suficiente. Por lo tanto, los valores finales son:

$$x = 1,82358$$

$$y = 2,02949$$

$$z = 1,73530$$

## 2.2. Sistema homogéneo

Encuentre las soluciones al sistema homogéneo:

$$\begin{cases} x + 2y + 3z = 0 \\ 2x + 4y + 6z = 0 \\ 3x + 6y + 9z = 0 \end{cases}$$

Si nos ponemos a analizar el sistema, nos encontramos con que en realidad todas las ecuaciones son un múltiplo de la primera, la ecuación2 es 2\*ecuación1, mientras que la ecuación3 = 3\*ecuación1. Por lo que podemos afirmar que no existe una única solución, sino infinitas.

Como simplificamos todo a un solo vector, entonces, para obtener una solución factible para el problema, es necesario definir dos valores, y en base a ellos se definirá la otra variable, veamos:

$$x + 2y + 3z = 0$$

$$x = -2y - 3z$$

Si  $y = 2, z = 1 \rightarrow x = -2(2) - 3(1) = -7$ .

Sustituimos los valores en la ecuacion:

$$(-7) + (2)(2) + (3)(1) = -7 + 4 + 3 = 0.$$

Por lo tanto, si queremos obtener una solución factible, solo tenemos que definir dos variables  $(y, z)$  y obtener  $x$  dado:

$$\begin{bmatrix} x \\ y \\ z \end{bmatrix} = y \begin{bmatrix} -2 \\ 1 \\ 0 \end{bmatrix} + z \begin{bmatrix} -3 \\ 0 \\ 1 \end{bmatrix}, \quad \text{con } y, z \in \mathbb{R}.$$

### 3. Espacios vectoriales y auto-valores/auto-vectores

#### 3.1. Bases y dimensión

Encuentre la base y la dimensión del subespacio generado por los vectores  $(1,2,3), (2,4,6), (3,6,9)$ .

##### 3.1.1. Notación

Para encontrar la base y dimensión de un conjunto de vectores, escribimos estos como una matriz, obteniendo:

$$A = \begin{pmatrix} 1 & 2 & 3 \\ 2 & 4 & 6 \\ 3 & 6 & 9 \end{pmatrix}$$

Y hacemos las operaciones necesarias para llevar la matriz a su forma escalonada. Como son vectores dependientes, entonces:

$$A = \begin{pmatrix} 1 & 2 & 3 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \end{pmatrix}$$

##### 3.1.2. Dimensión

La matriz escalonada tiene una única fila **no nula**, lo que indica que el rango de la matriz es 1 ( $\rho(A) = 1$ ), esto significa que la dimensión del subespacio generado (o dimensión de la imagen de A) es 1.

##### 3.1.3. Base

La única fila no nula en la matriz escalonada es  $(1,2,3)$ , lo que indica que este vector es suficiente para generar el subespacio.

Por lo tanto, la base del subespacio es:

$$B(A) = \left\{ \begin{bmatrix} 1 \\ 2 \\ 3 \end{bmatrix} \right\}$$

### 3.2. Autovalores y autovectores

Determine los autovalores y autovectores de la matriz:

$$G = \begin{bmatrix} 5 & -2 \\ -2 & 5 \end{bmatrix}$$

**Definición** Sea  $A$  una matriz de  $n \times n$  con componentes reales, el número  $\lambda$  (real o complejo) se llama eigenvalor (autovalor) de  $A$  si existe un vector diferente de 0  $v \in \mathbb{C}^n$  tal que:

$$A \cdot v = \lambda v$$

Como  $A \cdot v = \lambda v$ , entonces:

$$\rightarrow A \cdot v - \lambda I v = 0$$

$$\rightarrow (A - \lambda I) \cdot v = 0$$

con  $v$  como e núcleo de  $A - \lambda I$ .

**Teorema** Sea  $A$  una matriz de dimensión  $n \times n$ , entonces  $\lambda$  es un valor propio de  $A$  si y solo si:

$$p(\lambda) = |A - \lambda I| = 0$$

$$\rightarrow \det(A - \lambda I) = 0$$

#### 3.2.1. Obtención de autovalores

$$\text{Sea } G = \begin{bmatrix} 5 & -2 \\ -2 & 5 \end{bmatrix} \text{ y } \lambda I = \begin{bmatrix} \lambda & 0 \\ 0 & \lambda \end{bmatrix}, \text{ entonces: } G - \lambda I = \begin{bmatrix} 5 - \lambda & -2 \\ -2 & 5 - \lambda \end{bmatrix}$$

Aplicando el determinante a la matriz resultante:

$$\det(G - \lambda I) = \begin{vmatrix} 5 - \lambda & -2 \\ -2 & 5 - \lambda \end{vmatrix} = (5 - \lambda)^2 - (-2)^2 = 0$$

$$\rightarrow (5 - \lambda)^2 - (-2)^2 = 0 = (25 - 10\lambda + \lambda^2) - (4) = 0$$

$$\rightarrow \lambda^2 - 10\lambda + 21 = 0$$

Factorizando:

$$\rightarrow (\lambda - 3)(\lambda - 7) = 0$$

Resolviendo:

$$\lambda = 3$$

$$\lambda = 7$$



### 3.2.2. Obtención de autovectores

**Para  $\lambda = 3$**

$$\begin{bmatrix} 5-3 & -2 \\ -2 & 5-3 \end{bmatrix} = \begin{bmatrix} 2 & -2 \\ -2 & 2 \end{bmatrix}$$

Multiplicamos la matriz resultante por (x,y) e igualamos a 0:

$$\begin{bmatrix} 2 & -2 \\ -2 & 2 \end{bmatrix} \cdot \begin{bmatrix} x \\ y \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$$

Y resolviendo el sistema de ecuaciones, encontramos que el eigenvector asociado a  $\lambda = 3$  es:

$$v_1 = k_1 \begin{bmatrix} 1 \\ 1 \end{bmatrix}$$

**Para  $\lambda = 7$**

$$\begin{bmatrix} 5-7 & -2 \\ -2 & 5-7 \end{bmatrix} = \begin{bmatrix} -2 & -2 \\ -2 & -2 \end{bmatrix}$$

Multiplicamos la matriz resultante por (x,y) e igualamos a 0:

$$\begin{bmatrix} -2 & -2 \\ -2 & -2 \end{bmatrix} \cdot \begin{bmatrix} x \\ y \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$$

Y resolviendo el sistema de ecuaciones, encontramos que el eigenvector asociado a  $\lambda = 7$  es:

$$v_2 = k_2 \begin{bmatrix} -1 \\ 1 \end{bmatrix}$$

## 4. Aplicaciones de la IA: reducción de dimensionalidad

### 4.1. Análisis de Componentes Principales (PCA)

Reduce la dimensionalidad de los datos usando álgebra lineal, maximizando la varianza retenida.

#### 4.1.1. Centralización

Se resta la media de cada variable para centrar los datos en el origen.

#### 4.1.2. Matriz de covarianza

Se calcula como:

$$C = \frac{1}{n-1} X^T X$$

para analizar la relación entre variables.

#### 4.1.3. Autovalores y autovectores

Se resuelve:

$$Cv = \lambda v$$

- **Autovalores:** indican la varianza explicada.
- **Autovectores:** definen las direcciones principales.

#### 4.1.4. Proyección

Se eligen los  $k$  autovectores con mayores autovalores y se proyectan los datos:

$$X' = XW$$

reduciendo la dimensión sin perder mucha información.

### 4.2. Descomposición en valores singulares (SVD)

Calcule la descomposición en valores singulares de la matriz:

$$H = \begin{pmatrix} 3 & 1 \\ 2 & 2 \end{pmatrix}$$

#### 4.2.1. Calcular $H^T H$ y sus valores propios

$$H = \begin{pmatrix} 3 & 1 \\ 2 & 2 \end{pmatrix} \qquad H^T = \begin{pmatrix} 3 & 2 \\ 1 & 2 \end{pmatrix}$$

$$H^T H = \begin{pmatrix} 3 & 2 \\ 1 & 2 \end{pmatrix} \cdot \begin{pmatrix} 3 & 1 \\ 2 & 2 \end{pmatrix} = \begin{pmatrix} 9+4 & 3+4 \\ 3+4 & 1+4 \end{pmatrix} = \begin{pmatrix} 13 & 7 \\ 7 & 5 \end{pmatrix}$$

#### 4.2.2. Valores y vectores propios de $H^T H$

$$\begin{vmatrix} 13 - \lambda & 7 \\ 7 & 5 - \lambda \end{vmatrix} = (13 - \lambda)(5 - \lambda) - 7^2 = 65 - 18\lambda + \lambda^2 - 49 \\ = \lambda^2 - 18\lambda + 16 = 0$$

Resolviendo con la fórmula general:

$$\lambda = \frac{18 \pm \sqrt{(-18)^2 - 4(1)(16)}}{2(1)} = \frac{18 \pm \sqrt{260}}{2} = 9 \pm \sqrt{65}$$

$$\rightarrow \lambda_1 = 17,062 \quad \lambda_2 = 0,9377$$

#### Vectores propios

Para  $\lambda_1 = 17,062$ :

$$\begin{bmatrix} -4,062 & 7 \\ 7 & -12,062 \end{bmatrix} \cdot \begin{bmatrix} x \\ y \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$$

Obteniendo:

$$v_1 = k_1 \begin{bmatrix} \frac{1}{7}(4 + \sqrt{65}) \\ 1 \end{bmatrix}$$

Para  $\lambda_2 = 0,9377$ :

$$\begin{bmatrix} 12,0623 & 7 \\ 7 & 4,0623 \end{bmatrix} \cdot \begin{bmatrix} x \\ y \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$$

Obteniendo:

$$v_2 = k_2 \begin{bmatrix} \frac{1}{7}(4 - \sqrt{65}) \\ 1 \end{bmatrix}$$

#### 4.2.3. Obtención de $U$ y $V$

Partimos de:

$$H = U \Sigma V^T$$

donde  $U$  y  $V$  son matrices ortogonales y  $\Sigma$  es una matriz diagonal con los valores singulares.

Los vectores propios  $v_1$  y  $v_2$  forman las columnas de la matriz  $V$ :

$$V = \begin{pmatrix} \frac{1}{7}(12,062) & \frac{1}{7}(-4,062) \\ 1 & 1 \end{pmatrix}$$

La matriz  $\Sigma$  está definida por los valores singulares (raíz cuadrada de los valores propios) en la diagonal:

$$\Sigma = \begin{pmatrix} \sqrt{17,062} & 0 \\ 0 & \sqrt{0,9377} \end{pmatrix} \approx \begin{pmatrix} 4,13 & 0 \\ 0 & 0,97 \end{pmatrix}$$

La matriz  $U$  se obtiene usando la relación  $HV = U\Sigma \rightarrow HV\Sigma^T = U$ , se definen las columnas de  $U$  como:

$$u_1 = \frac{1}{\sigma_1} H v_1 = \frac{1}{4,13} \begin{pmatrix} 3 & 1 \\ 2 & 2 \end{pmatrix} \begin{pmatrix} \frac{1}{7}(12,062) \\ 1 \end{pmatrix}$$

$$u_2 = \frac{1}{\sigma_2} H v_2 = \frac{1}{0,97} \begin{pmatrix} 3 & 1 \\ 2 & 2 \end{pmatrix} \begin{pmatrix} \frac{1}{7}(-4,062) \\ 1 \end{pmatrix}$$

Encontramos que:

$$U = \begin{pmatrix} \frac{\frac{3}{7}(12,062)+1}{4,13} & \frac{\frac{3}{7}(-4,062)+1}{0,97} \\ \frac{\frac{2}{7}(12,062)+2}{4,13} & \frac{\frac{2}{7}(-4,062)+2}{0,97} \end{pmatrix}$$

## Descomposición

Por último, la descomposición en valores singulares queda de la siguiente forma:

$$H = U\Sigma V^T =$$

$$\begin{pmatrix} \frac{\frac{3}{7}(12,062)+1}{4,13} & \frac{\frac{3}{7}(-4,062)+1}{0,97} \\ \frac{\frac{2}{7}(12,062)+2}{4,13} & \frac{\frac{2}{7}(-4,062)+2}{0,97} \end{pmatrix} \cdot \begin{pmatrix} \sqrt{9 + \sqrt{65}} & 0 \\ 0 & \sqrt{9 - \sqrt{65}} \end{pmatrix} \cdot \begin{pmatrix} \frac{1}{7}(4 + \sqrt{65}) & 1 \\ \frac{1}{7}(4 - \sqrt{65}) & 1 \end{pmatrix}$$

## 4.3. Álgebra Líneal en aprendizaje profundo

### 4.3.1. Representación de Datos

Los datos de entrada se representan como vectores o matrices. Una imagen, por ejemplo, se almacena como una matriz de píxeles, y un conjunto de datos completo se modela como una matriz donde cada fila es una muestra y cada columna una característica.

### 4.3.2. Pesos y Operaciones Lineales

Las conexiones entre neuronas tienen pesos que se almacenan en matrices. La propagación de la información en la red se realiza mediante productos de matrices:

$$Z = WX + b$$

donde  $W$  es la matriz de pesos,  $X$  la entrada y  $b$  el sesgo.

### 4.3.3. Funciones de Activación

Las funciones de activación transforman la salida de cada neurona. Aunque algunas son no lineales (ReLU, sigmoide, tanh), sus derivadas se utilizan en el cálculo del gradiente.

#### 4.3.4. Propagación Hacia Atrás y Gradientes

El entrenamiento de redes neuronales usa el algoritmo de retropropagación, basado en el cálculo del gradiente mediante la regla de la cadena. Se utilizan derivadas parciales y el producto de matrices para actualizar los pesos:

$$W^{(t+1)} = W^{(t)} - \alpha \nabla L$$

donde  $\alpha$  es la tasa de aprendizaje y  $\nabla L$  el gradiente de la función de pérdida.

#### 4.3.5. Descomposición en Valores Singulares (SVD)

SVD permite reducir la dimensionalidad de los datos y comprimir modelos. Se descompone una matriz  $A$  en:

$$A = U \Sigma V^T$$

donde  $U$  y  $V$  son ortogonales, y  $\Sigma$  contiene los valores singulares.

### 4.4. Impacto de espacios vectoriales en representación de datos en IA

#### 4.4.1. Representación de Datos

En IA, los datos se representan como vectores en espacios multidimensionales. Palabras, imágenes y señales se transforman en vectores numéricos para facilitar su procesamiento.

#### 4.4.2. Distancias y Similitud

El álgebra lineal permite medir similitudes entre datos mediante distancias euclidianas y coseno del ángulo entre vectores, fundamentales en algoritmos de clasificación y clustering.

#### 4.4.3. Reducción de Dimensionalidad

Técnicas como PCA proyectan datos a subespacios de menor dimensión, eliminando redundancias sin perder información clave, optimizando modelos de IA.

#### 4.4.4. Espacios Latentes

Modelos como autoencoders y Word2Vec aprenden representaciones compactas de datos en espacios latentes, permitiendo tareas como generación de texto y compresión de imágenes.